

# Teoria erorilor și aritmetică în virgulă flotantă

Erorile sunt omniprezente

Radu Tiberiu Trîmbițaș

Universitatea "Babeș-Bolyai"

Februarie 2010

# Tipuri de erori

Aprecierea preciziei rezultatelor calculelor este un obiectiv important în Analiza numerică. Se disting mai multe tipuri de erori care pot limita această precizie:

- ❶ **erori în datele de intrare** - sunt în afara (dincolo de) controlului calculelor. Ele se pot datora, de exemplu, imperfecțiunilor inerente ale măsurătorilor fizice.
- ❷ **erori de rotunjire** - apar dacă se fac calcule cu numere a căror reprezentare se restrânge la un număr finit de cifre.
- ❸ **erori de aproximare** - multe metode nu dau soluția exactă a problemei  $P$ , ci a unei probleme mai simple  $\tilde{P}$ , care aproximează  $P$ : integralele se aproximează prin sume finite, derivatele prin diferențe (divizate), etc. Aceste erori se numesc **erori de discretizare**.

# Exemplu de eroare de aproximare

- (P) Dorim să aproximăm

$$e = 1 + \frac{1}{1!} + \cdots + \frac{1}{n!} + \dots$$

- Problema se înlocuiește cu problema mai simplă ( $\tilde{P}$ ) a însumării unui număr finit de termeni -eroare se trunchiere

$$(\tilde{P}) \quad e = 1 + \frac{1}{1!} + \cdots + \frac{1}{n!}.$$

- În acest capitol ne interesează doar erorile în datele de intrare și erorile de rotunjire.

- Combinația dintre o problemă matematică (PM), (de natură constructivă) și specificațiile de precizie ale rezultatului (SP) se numește **problemă numerică**.

- Combinația dintre o problemă matematică (PM), (de natură constructivă) și specificațiile de precizie ale rezultatului (SP) se numește **problemă numerică**.
- Exemplu: Fie  $f : \mathbb{R} \rightarrow \mathbb{R}$  și  $x \in \mathbb{R}$ . Dorim să calculăm  $y = f(x)$ . În general  $x$  nu este reprezentabil în calculator; din acest motiv vom lucra cu o aproximare  $x^*$  a sa,  $x^* \approx x$ . De asemenea este posibil ca  $f$  să nu poată fi calculată exact; vom înlocui  $f$  cu o aproximantă a sa  $f_A$ . Valoarea calculată în calculator va fi  $f_A(x^*)$ . Deci problema numerică este următoarea:

- Combinația dintre o problemă matematică (PM), (de natură constructivă) și specificațiile de precizie ale rezultatului (SP) se numește **problemă numerică**.
- Exemplu: Fie  $f : \mathbb{R} \rightarrow \mathbb{R}$  și  $x \in \mathbb{R}$ . Dorim să calculăm  $y = f(x)$ . În general  $x$  nu este reprezentabil în calculator; din acest motiv vom lucra cu o aproximare  $x^*$  a sa,  $x^* \approx x$ . De asemenea este posibil ca  $f$  să nu poată fi calculată exact; vom înlocui  $f$  cu o aproximantă a sa  $f_A$ . Valoarea calculată în calculator va fi  $f_A(x^*)$ . Deci problema numerică este următoarea:

**PM.** dându-se  $x$  și  $f$ , să se calculeze  $f(x)$ ;

- Combinația dintre o problemă matematică (PM), (de natură constructivă) și specificațiile de precizie ale rezultatului (SP) se numește **problemă numerică**.
- Exemplu: Fie  $f : \mathbb{R} \rightarrow \mathbb{R}$  și  $x \in \mathbb{R}$ . Dorim să calculăm  $y = f(x)$ . În general  $x$  nu este reprezentabil în calculator; din acest motiv vom lucra cu o aproximare  $x^*$  a sa,  $x^* \approx x$ . De asemenea este posibil ca  $f$  să nu poată fi calculată exact; vom înlocui  $f$  cu o aproximantă a sa  $f_A$ . Valoarea calculată în calculator va fi  $f_A(x^*)$ . Deci problema numerică este următoarea:

**PM.** dându-se  $x$  și  $f$ , să se calculeze  $f(x)$ ;

**SP.**  $|f(x) - f_A(x^*)| < \varepsilon$ ,  $\varepsilon$  dat.

- $X$  spațiu liniar normat,  $A \subseteq X$ ,  $x \in X$ . Un element  $x^* \in A$  se numește **aproximantă** a lui  $x$  din  $A$  (notație  $x^* \approx x$ ).
- $x^* \approx x$  o aproximantă a lui  $x$ , diferența  $\Delta x = x - x^*$  se numește **eroare**, iar

$$\|\Delta x\| = \|x^* - x\| \quad (1)$$

se numește **eroare absolută**.

•

$$\delta x = \frac{\|\Delta x\|}{\|x\|}, \quad x \neq 0 \quad (2)$$

se numește **eroare relativă**.

- Deoarece în practică  $x$  este necunoscut, se folosește aproximarea  $\delta x = \frac{\|\Delta x\|}{\|x^*\|}$ . Dacă  $\|\Delta x\|$  este mic comparativ cu  $\|x^*\|$ , atunci aproximanta este bună.



# Eroarea propagată

- $f : \mathbb{R}^n \longrightarrow \mathbb{R}$ ,  $x = (x_1, \dots, x_n)$ ,  $x^* = (x_1^*, \dots, x_n^*)$ . Dorim să evaluăm eroarea absolută și relativă  $\Delta f$  și respectiv  $\delta f$  când se aproximează  $f(x)$  prin  $f(x^*)$ .
- Aceste erori se numesc **erori propagate**, deoarece ne spun cum se propagă eroarea inițială (absolută sau relativă) pe parcursul calculării lui  $f$ .
- Presupunem  $x = x^* + \Delta x$ ,  $\Delta x = (\Delta x_1, \dots, \Delta x_n)$ . Aplicăm formula lui Taylor

$$\begin{aligned}\Delta f &= f(x_1^* + \Delta x_1, \dots, x_n^* + \Delta x_n) - f(x_1^*, \dots, x_n^*) \\ &= \sum_{i=1}^n \Delta x_i \frac{\partial f}{\partial x_i^*}(x_1^*, \dots, x_n^*) + \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \Delta x_i \Delta x_j \frac{\partial^2 f}{\partial x_i^* \partial x_j^*}(\theta),\end{aligned}$$

$$\theta \in [(x_1^*, \dots, x_n^*), (x_1^* + \Delta x_1, \dots, x_n^* + \Delta x_n)].$$

- neglijând termenii de ordinul al doilea (mici) obținem

$$\Delta f \approx \sum_{i=1}^n \Delta x_i \frac{\partial f}{\partial x_i^*}(x_1^*, \dots, x_n^*). \quad (3)$$

- Pentru eroarea relativă avem

$$\begin{aligned} \delta f &= \frac{\Delta f}{f} \approx \sum_{i=1}^n \Delta x_i \frac{\frac{\partial f}{\partial x_i^*}(x^*)}{f(x^*)} \\ &= \sum_{i=1}^n \delta x_i \frac{x_i^* \frac{\partial f}{\partial x_i^*}(x^*)}{f(x^*)} \end{aligned} \quad (4)$$

# Eroarea propagată III

- Problema inversă: cu ce precizie trebuie approximate datele pentru ca rezultatul să aibă o precizie dată?
- Adică, dându-se  $\varepsilon > 0$ , cât trebuie să fie  $\Delta x_i$  sau  $\delta x_i$ ,  $i = \overline{1, n}$  astfel încât  $\Delta f$  sau  $\delta f < \varepsilon$ ?
- **principiul efectelor egale**: se presupune că toți termenii care intervin în (3) sau (4) au același efect, adică

$$\frac{\partial f}{\partial x_1^*}(x^*)\Delta x_1 = \dots = \frac{\partial f}{\partial x_n^*}(x^*)\Delta x_n.$$

- se obține

$$\Delta x_i \approx \frac{\Delta f}{n \left| \frac{\partial f}{\partial x_i^*}(x^*) \right|}. \quad (5)$$

$$\delta x_i = \frac{\delta f}{n \left| \frac{x_i^* \frac{\partial}{\partial x_i^*} f(x^*)}{f(x^*)} \right|}. \quad (6)$$

**Exemplu.** Găsiți o margine a erorii absolute și relative pentru volumul sferei  $V = \frac{\pi d^3}{6}$  cu diametrul egal cu  $3.7\text{cm} \pm 0.04\text{cm}$  și  $\pi \approx 3.14$ .

- Calculăm derivatele parțiale

$$\frac{\partial V}{\partial \pi} = \frac{1}{6}d^3 = 8.44, \quad \frac{\partial V}{\partial d} = \frac{1}{2}\pi d^2 = 21.5.$$

- Aplicând formula (3) și definiția erorii relative obținem:

$$\Delta V = \left| \frac{\partial V}{\partial \pi} \right| |\Delta \pi| + \left| \frac{\partial V}{\partial d} \right| |\Delta d| = 8.44 + 21.5 \cdot 0.05 \approx 1.0888,$$

$$\delta_V = \frac{1.0888}{274} \approx 4\%.$$

## Exemple - continuare

**Exemplu.** Un cilindru are raza  $R \approx 2m$ , înălțimea  $H \approx 3m$ . Cu ce erori absolute trebuie determinate  $R$ ,  $H$  și  $\pi$  astfel încât  $V$  să poată fi calculat cu o eroare  $< 0.1m^3$ .

Se aplică principiul efectelor egale (5):

$$V = \pi R^2 H, \quad \Delta V = 0.1m^3,$$

$$\frac{\partial V}{\partial \pi} = R^2 H = 12, \quad \frac{\partial V}{\partial R} = 2\pi R H = 37.7, \quad \frac{\partial V}{\partial H} = \pi R^2 = 12.6.$$

$n = 3$ , erorile absolute ale argumentelor:

$$\Delta \pi \approx \frac{\Delta V}{3 \frac{\partial V}{\partial \pi}} = \frac{0.1}{3.12} < 0.003,$$

$$\Delta R \approx \frac{0.1}{3 \cdot 37.7} < 0.001,$$

$$\Delta H \approx \frac{0.1}{3 \cdot 12.6} < 0.003.$$

# Aritmetică în virgulă flotantă

## Parametrii reprezentării

- Parametrii reprezentării în virgulă flotantă sunt următoarele numere naturale
  - **baza**  $\beta$  (întotdeauna pară);
  - **precizia**  $p$ ;
  - **exponentul maxim**  $e_{\max}$ ;
  - **exponentul minim**  $e_{\min}$ ;
- În general, un număr în virgulă flotantă se reprezintă sub forma

$$x = \pm d_0.d_1d_2\dots d_{p-1} \times \beta^e, \quad 0 \leq d_i < \beta \quad (7)$$

$d_0.d_1d_2\dots d_{p-1}$  - **semnificant** sau **mantisă**,  $e$  **exponent**.

- Valoarea lui  $x$  este

$$\pm (d_0 + d_1\beta^{-1} + d_2\beta^{-2} + \dots + d_{p-1}\beta^{-(p-1)})\beta^e. \quad (8)$$

# Parametrii reprezentării


- Unicitatea se asigură prin **normalizare**: se modifică reprezentarea (nu valoarea) astfel încât  $d_0 \neq 0$ .
- Zero se reprezintă ca  $1.0 \times \beta^{e_{\min}-1}$
- Ordinea numerică uzuală a numerelor reale nenegative corespunde ordinii lexicografice a reprezentării lor flotante (cu exponentul în stânga semnificantului).
- **număr în virgulă flotantă** = număr real care poate fi reprezentat exact în virgulă flotantă

# Numere denormalizate

- După normalizarea semnificanților rămâne un „gol” între 0 și  $\beta^{e_{\min}}$
- Aceasta poate avea ca efect  $x - y = 0$  chiar dacă  $x \neq y$ , iar un fragment de cod de tipul **if**  $x \neq y$  **then**  $z = 1/(x - y)$  poate eșua
- Soluție: se admit semnificanți nenormalizați când exponentul este  $e_{\min}$  (gradual underflow). Aceste numere se numesc **numere denormalizate**. Ele garantează că

$$x = y \iff x - y = 0$$

- Distribuția fără denormalizare și cu denormalizare





# Parametrii reprezentării

- Mulțimea numerelor în virgulă flotantă pentru un set de parametri dați ai reprezentării se va nota cu

$$\mathbb{F}(\beta, p, e_{\min}, e_{\max}, \text{denorm}), \quad \text{denorm} \in \{true, false\}.$$

- Această mulțime nu coincide cu  $\mathbb{R}$  din următoarele motive:
  - ① este o submulțime finită a lui  $\mathbb{Q}$ ;
  - ② pentru  $x \in \mathbb{R}$  putem avea  $|x| > \beta \times \beta^{e_{\max}}$  (depășire superioară) sau  $|x| < 1.0 \times \beta^{e_{\min}}$  (depășire inferioară).
- Operațiile aritmetice uzuale pe  $\mathbb{F}(\beta, p, e_{\min}, e_{\max}, \text{denorm})$  se notează cu  $\oplus$ ,  $\ominus$ ,  $\otimes$ ,  $\oslash$ , iar funcțiile uzuale cu SIN, COS, EXP, LN, SQRT ș.a.m.d.  $(\mathbb{F}, \oplus, \otimes)$  nu este corp deoarece

$$\begin{aligned}(x \oplus y) \oplus z &\neq x \oplus (y \oplus z) & (x \otimes y) \otimes z &\neq x \otimes (y \otimes z) \\ (x \oplus y) \otimes z &\neq x \otimes z \oplus y \otimes z.\end{aligned}$$

- Eroarea relativă
- ulps** – **u**nits in the **l**ast **p**lace (unități în ultima poziție): dacă  $z = d_0.d_1d_2 \dots d_{p-1} \dots \times \beta^e$ , atunci eroarea este

$$|d_0.d_1d_2 \dots d_{p-1} - z/\beta^e| \beta^{p-1} \text{ulps.}$$

- Eroarea relativă ce corespunde la  $\frac{1}{2}$ ulps este

$$\frac{1}{2}\beta^{-p} \leq \frac{1}{2}\text{ulps} \leq \frac{\beta}{2}\beta^{-p},$$

căci eroarea absolută este  $\underbrace{0.0 \dots 0}_p \beta' \times \beta^e$ , cu  $\beta' = \frac{\beta}{2}$ . Valoarea

$\text{eps} = \frac{\beta}{2}\beta^{-p}$  se numește **epsilon-ul mașinii**.

- Echivalent rezoluția relativă (distanța relativă între doi vecini)

- Rotunjirea implicită se face după regula cifrei pare: dacă  $x = d_0.d_1 \dots d_{p-1}d_p \dots$  și  $d_p > \frac{\beta}{2}$  rotunjirea se face în sus, dacă  $d_p < \frac{\beta}{2}$  rotunjirea se face în jos, iar dacă  $d_p = \frac{\beta}{2}$  și printre cifrele eliminate există una nenulă rotunjirea se face în sus, iar în caz contrar ultima cifră păstrată este pară.
- Alte tipuri de rotunjiri: în jos, în sus, spre zero, trunchiere

# Aritmetică în virgulă flotantă

- Definim  $\text{fl}(x)$  ca fiind cea mai apropiată aproximare în virgulă flotantă a lui  $x$
- Din definiția  $\text{eps}$  avem pentru eroarea relativă:

$$\forall x \in \mathbb{R}, \exists \epsilon \text{ cu } |\epsilon| \leq \text{eps} \text{ astfel încât } \text{fl}(x) = x(1 + \epsilon)$$

- Rezultatul unei operații  $\odot$  în virgulă flotantă este  $\text{fl}(a \circ b)$
- Dacă  $\text{fl}(a \circ b)$  este cel mai apropiat număr în virgulă flotantă de  $a \circ b$ , operațiile aritmetice se rotunjesc corect (standardul IEEE o face), ceea ce ne conduce la următoarea proprietate:

*Pentru orice numere în virgulă flotantă  $x, y$ , există  $\epsilon$  cu  $|\epsilon| \leq \text{eps}$  astfel încât*

$$x \odot y = (x \circ y)(1 + \epsilon)$$

**numită axioma fundamentală a aritmeticii în virgulă flotantă**

- Rotunjire la cel mai apropiat par în caz de ambiguitate

- Din formulele pentru eroarea relativă (4), dacă  $x \approx x(1 + \delta_x)$  și  $y \approx y(1 + \delta_y)$ , avem următoarele expresii pentru erorile relative ale operațiilor în virgulă flotantă:

$$\delta_{xy} = \delta_x + \delta_y \quad (9)$$

$$\delta_{x/y} = \delta_x - \delta_y \quad (10)$$

$$\delta_{x+y} = \frac{x}{x+y} \delta_x + \frac{y}{x+y} \delta_y \quad (11)$$

- Singura operație critică din punct de vedere al erorii este scăderea a două cantități apropiate  $x \approx y$ , caz în care  $\delta_{x-y} \rightarrow \infty$ .
- Acest fenomen se numește **anulare**

- Anularea este de două tipuri:
  - ① **benignă**, când se scad două cantități exacte
  - ② **catastrofală**, când se scad două cantități deja rotunjite.
- Programatorul trebuie să fie conștient de posibilitatea apariției anulării și să încerce să o evite.
- Expresiile în care apare anularea trebuie rescrise, iar o anulare catastrofală trebuie întotdeauna transformată în una benignă.

- **Exemplu.** Dacă  $a \approx b$ , atunci expresia  $a^2 - b^2$  se transformă în  $(a - b)(a + b)$ . Forma inițială este de preferat în cazul când  $a \gg b$  sau  $b \gg a$ .
- **Exemplu.** Dacă anularea apare într-o expresie cu radicali, se amplifică cu conjugata:

$$\sqrt{x + \delta} - \sqrt{x} = \frac{\delta}{\sqrt{x + \delta} + \sqrt{x}}, \quad \delta \approx 0.$$

- **Exemplu.** Diferența valorilor unei funcții pentru argumente apropiate se transformă folosind formula lui Taylor:

$$f(x + \delta) - f(x) = \delta f'(x) + \frac{\delta^2}{2} f''(x) + \dots \quad f \in C^n[a, b].$$

# Anularea IV

La ecuația de gradul al doilea  $ax^2 + bx + c = 0$ , anularea poate să apară dacă  $b^2 \gg 4ac$ . Formulele uzuale

$$x_1 = \frac{-b + \sqrt{b^2 - 4ac}}{2a} \quad (12)$$

$$x_2 = \frac{-b - \sqrt{b^2 - 4ac}}{2a} \quad (13)$$

pot să conducă la anulare astfel: pentru  $b > 0$  anularea apare la calculul lui  $x_1$ , iar pentru  $b < 0$  anularea apare la calculul lui  $x_2$ . Remediul este să amplificăm cu conjugata

$$x_1 = \frac{2c}{-b - \sqrt{b^2 - 4ac}} \quad (14)$$

$$x_2 = \frac{2c}{-b + \sqrt{b^2 - 4ac}} \quad (15)$$

și să utilizăm în primul caz formulele (14) și (13), iar în al doilea caz (12) și (15). [../demo/html/ecgr2.html](http://demo/html/ecgr2.html)



# Teorema asupra pierderii preciziei

- Problemă: Câte cifre semnificative se pierde la scăderea  $x - y$  când  $x$  este apropiat de  $y$ ?
- Apropierea lui  $x$  de  $y$  este măsurată convenabil de  $1 - \frac{y}{x}$ .

## Teoremă (Loss of precision theorem)

Fie  $x$  și  $y$  NVF normalizate, unde  $x > y > 0$ . Dacă

$$2^{-p} \leq 1 - \frac{y}{x} \leq 2^{-q}$$

pentru  $p, q \in \mathbb{N}$ , atunci se pierde cel puțin  $q$  și cel mult  $p$  cifre binare semnificative la scăderea  $x - y$ .

# Teorema asupra pierderii preciziei - demonstrație

## Demonstrație.

Vom demonstra partea a doua, lăsând prima parte ca exercițiu. Fie  $x = s \times 2^n$ ,  $y = r \times 2^m$  NVF normalizate. Deoarece  $y < x$ ,  $y$  va trebui deplasat înaintea scăderii, pentru a avea același exponent ca  $x$ . Deci,  $y = (s2^{m-n}) \times 2^n$  și

$$x - y = (r - s2^{m-n}) \times 2^n$$

Semnificantul satisface

$$r - s2^{m-n} = r \left( 1 - \frac{r \times 2^m}{s \times 2^n} \right) = r \left( 1 - \frac{y}{x} \right) < 2^{-q}$$

Deci, pentru normalizarea reprezentării lui  $x - y$ , este nevoie de o deplasare de  $q$  biți la stânga. Astfel se introduc cel puțin  $q$  zerouri false la capătul drept al semnificantului. Aceasta înseamnă o pierdere a preciziei de cel puțin  $q$  biți. □

## Exemplu

*Pentru  $\sin x$ , câți biți semnificativi se pierd la reducerea la intervalul  $[0, 2\pi)$ ?*

**Soluție.** Dându-se  $x > 2\pi$ , vom determina întregul  $n$  ce satisface  $0 \leq x - 2n\pi < 2\pi$ . Apoi la evaluare vom utiliza periodicitatea  $f(x) = f(x - 2n\pi)$ . La scăderea  $x - 2n\pi$ , va fi o pierdere de precizie. Conform teoremei 1 se vor pierde cel puțin  $q$  biți dacă

$$1 - \frac{2n\pi}{x} \leq 2^{-q}$$

Deoarece

$$1 - \frac{2n\pi}{x} = \frac{x - 2n\pi}{x} < \frac{2\pi}{x}$$

conchidem că cel puțin  $q$  biți se pierd dacă  $2\pi/x < 2^{-q}$ , sau echivalent, dacă  $2^q < x/2\pi$ . ■

**Exemplu numeric.** Să se calculeze  $\sin(12532.14)$ .

Avem  $\sin(12532.14) = \sin(12532.14 - 2k\pi)$ , cu  $k = 1994$  și  $12532.14 - 2k\pi \approx 3.47$  și rezultatul va fi eronat. Dacă reducerea s-ar fi putut face cu precizie mai bună și rezultatul ar fi fost mai bun. MATLAB dă  $\sin(12532.14) = -0.321113319309938$  și  $\sin(3.47) = -0.322535900322479$ .

# Standardele IEEE

- Există două standarde diferite pentru calculul în virgulă flotantă:
  - 1 **IEEE 754** care prevede  $\beta = 2$
  - 2 **IEEE 854** care permite  $\beta = 2$  sau  $\beta = 10$ , dar lasă o mai mare libertate de reprezentare.
- Parametrii standardului IEEE 754

	Precizia			
	Simplă	Simplă extinsă	Dublă	Dublă extinsă
p	24	$\geq 32$	53	$\geq 64$
$e_{\max}$	+127	$\geq +1023$	+1023	$\geq +16383$
$e_{\min}$	-126	$\leq -1022$	-1022	$\leq -16382$
dim. exponent	8	$\geq 11$	11	$\geq 15$
dim. număr	32	$\geq 43$	64	$\geq 79$

**Tabela:** Parametrii reprezentării flotante

**bit ascuns** -  $d_0 = 1$ , deci nu trebuie reprezentat fizic

Motivele pentru formatele extinse sunt:

- ① o mai bună precizie;
- ② pentru conversia din binar în zecimal și invers este nevoie de 9 cifre în simplă precizie și de 17 cifre în dublă precizie.

Motivul pentru care  $|e_{min}| < e_{max}$  este acela că  $1/2^{e_{min}}$  nu trebuie să dea depășire.

Operațiile  $\oplus, \ominus, \otimes, \oslash$  trebuie să fie exact rotunjite. Precizia aceasta se asigură cu două cifre de gardă și un bit suplimentar.

Reprezentarea exponentului se numește **reprezentare cu exponent deplasat**, adică în loc de  $e$  se reprezintă  $e + D$ , unde  $D$  este fixat la alegerea reprezentării.

$D = 127$  pentru simplă precizie și  $D = 1023$  pentru dublă precizie.

Exponent	Semnificant	Ce reprezintă	
$e = e_{min} - 1$	$f = 0$	$\pm 0$	zero cu semn
$e = e_{min} - 1$	$f \neq 0$	$0.f \times 2^{e_{min}}$	Numere denormalizate
$e_{min} \leq e \leq e_{max}$		$1.f \times 2^e$	
$e = e_{max} + 1$	$f = 0$	$\pm \infty$	infinit
$e = e_{max} + 1$	$f \neq 0$	NaN	NaN-uri

**NaN.** Avem de fapt o familie de valori NaN, operațiile ilegale sau nedeterminate conduc la NaN:  $\infty + (-\infty)$ ,  $0 \times \infty$ ,  $0/0$ ,  $\infty/\infty$ ,  $x \text{ REM } 0$ ,  $\infty \text{ REM } y$ ,  $\sqrt{x}$  pentru  $x < 0$ . Dacă un operand este NaN rezultatul va fi tot NaN.

**Infinit.** Operațiile cu  $\infty$  se definesc ca limite, ex:  $1/0 = \infty$ ,  $-1/0 = -\infty$ . Valorile infinite dau posibilitatea continuării calculului, lucru mai sigur decât abortarea sau returnarea celui mai mare număr reprezentabil.  $\frac{x}{1+x^2}$  pentru  $x = \infty$  dă rezultatul 0.

**Zero cu semn.** Avem doi de 0:  $+0$ ,  $-0$ ; relațiile  $+0 = -0$  și  $-0 < +\infty$  sunt adevărate. Avantaje: tratarea simplă a depășirilor inferioare și discontinuităților. Se face distincție între  $\log 0 = -\infty$  și  $\log x = \text{NaN}$  pentru  $x < 0$ . Fără 0 cu semn nu s-ar putea face distincție la logaritm între un număr negativ care dă depășire superioară și 0.



# IEEE Simplă precizie, exemple

S	E	M	Cantitate
0	11111111	000001000000000000000000	NaN
1	11111111	00100010000100101010101	NaN
0	11111111	000000000000000000000000	$\infty$
0	10000001	101000000000000000000000	$+2^{129-127} \cdot 1.101 = 6.5$
0	10000000	000000000000000000000000	$+2^{128-127} \cdot 1.0 = 2$
0	00000001	000000000000000000000000	$+2^{1-127} \cdot 1.0 = 2^{-126}$
0	00000000	100000000000000000000000	$+2^{-126} \cdot 0.1 = 2^{-127}$
0	00000000	000000000000000000000001	$+2^{-126} \cdot 2^{-23} = 2^{-149}$
0	00000000	000000000000000000000000	+0
1	00000000	000000000000000000000000	-0
1	10000001	101000000000000000000000	$-2^{129-127} \cdot 1.101 = -6.5$
1	11111111	000000000000000000000000	$-\infty$

Pentru virgulă flotantă în MATLAB vezi `../demo/html/fpdemo.html`



**William Kahan**, eminent matematician și informatician, contribuții importante la studiul metodelor precise și eficiente de rezolvare a problemelor numerice pe calculatoare cu precizie finită. A fost principalul arhitect al standardului IEEE 754. Distins cu premiul Turing al ACM în 1989, Fellow al ACM din 1994. Profesor la Universitatea Berkeley, California

# Eșecul rachetei Patriot I



- Eșecul unui sistem de rachete antirachetă Patriot în timpul războiului din Golf din 1991 s-a datorat unei erori de conversie software.
- Ceasul sistemului măsoara timpul în zecimi de secundă, dar îl memora într-un registru de 24 de biți, provocându-se astfel erori de rotunjire.
- Datele din câmp au arătat că sistemul poate eșua să urmărească și să intercepteze o rachetă după 20 de ore de funcționare și deci sistemul ar necesita rebootare.

# Eșecul rachetei Patriot II

- După 100 de ore de funcționare, eșecul sistemului a cauzat moartea a 28 de soldați americani aflați într-o cazarmă din Dhahran, Arabia Saudită, deoarece nu a reușit să intercepteze o rachetă Scud irakiană. Deoarece numărul 0.1 are o dezvoltare infinită în binar (este o fracție periodică), valoare din registrul de 24 de biți este eronată

$$(0.00011001100110011001100)_2 \approx 0.95 \times 10^{-7}.$$

Eroarea de timp după o sută de ore a fost de 0.34 secunde. Viteza rachetei Scud este de 3750 mile/oră, rezultând o eroare în distanță de aproximativ 573.59 m.

# Explozia rachetei Ariane 5

- În 1996, racheta Ariane 5 lansată de Agenția Spațială Europeană a explodat la 40 de secunde după lansarea de la Kourou, Guyana Franceză.
- Investigația de după incident a arătat că componeta orizontală a vitezei a necesitat conversia unui număr flotant în dublă precizie într-un întreg pe 16 biți.
- Deoarece numărul era mai mare decât 32,767, cel mai mare întreg reprezentabil pe 16 biți, componentele de control au intrat în procedura de autodistrugere. Valoarea rachetei și a încărcăturii a fost de 500 de milioane de dolari.



Se pot găsi informații adiționale pe World Wide Web la adresa <http://www.ima.umn.edu/~arnold/disasters/> sau la <http://www5.in.tum.de/~huckle/bugse.html>. Există și alte consemnări ale calamităților ce ar fi putut fi evitate printr-o programare mai atentă, în special la utilizarea AVF.

# Condiționarea unei probleme

- Putem gândi o problemă ca o aplicație

$$f : \mathbb{R}^m \rightarrow \mathbb{R}^n, \quad y = f(x). \quad (16)$$

- Ne interesează sensibilitatea aplicației într-un punct dat  $x$  la mici perturbații ale argumentului, adică cât de mare sau cât de mică este perturbația lui  $y$  comparativ cu perturbația lui  $x$ .
- În particular, dorim să măsurăm gradul de sensibilitate printr-un singur număr, numărul de condiționare al aplicației  $f$  în punctul  $x$ . Vom presupune că  $f$  este calculată exact, cu precizie infinită.
- Condiționarea lui  $f$  este deci o proprietate inherentă a funcției  $f$  și nu depinde de nici o considerație algoritmică legată de implementarea sa.

# Condiționarea unei probleme

- Aceasta nu înseamnă că determinarea condiționării unei probleme este nerelevantă pentru orice soluție algoritmică a problemei.
- Soluția calculată cu (16),  $y^*$  (utilizând un algoritm specific și aritmetica în virgulă flotantă) este (și acest lucru se poate demonstra) soluția unei probleme „apropiate“

$$y^* = f(x^*) \quad (17)$$

cu

$$x^* = x + \delta \quad (18)$$

- distanța  $\|\delta\| = \|x^* - x\|$  poate fi estimată în termeni de precizie a mașinii
- dacă știm cât de tare sau cât de slab reacționează aplicația la mici perturbații, cum ar fi  $\delta$  în (18), putem spune ceva despre eroarea  $y^* - y$  a soluției cauzată de această perturbație.



# Condiționarea unei probleme

Fie  $x = [x_1, \dots, x_m]^T \in \mathbb{R}^m$ ,  $y = [y_1, \dots, y_n]^T \in \mathbb{R}^n$ ,  $y_\nu = f_\nu(x_1, \dots, x_m)$ ,  $\nu = \overline{1, n}$  —  $y_\nu$  va fi privit ca o funcție de o singură variabilă  $x_\mu$

$$\gamma_{\nu\mu} = (\text{cond}_{\nu\mu} f)(x) = \left| \frac{x_\mu \frac{\partial f_\nu}{\partial x_\mu}}{f_\nu(x)} \right|. \quad (19)$$

Aceasta ne dă o matrice de numere de condiționare

$$\Gamma(x) = \begin{pmatrix} \frac{x_1 \frac{\partial f_1}{\partial x_1}}{f_1(x)} & \cdots & \frac{x_m \frac{\partial f_1}{\partial x_m}}{f_1(x)} \\ \vdots & \ddots & \vdots \\ \frac{x_1 \frac{\partial f_n}{\partial x_1}}{f_n(x)} & \cdots & \frac{x_m \frac{\partial f_n}{\partial x_m}}{f_n(x)} \end{pmatrix} =: [\gamma_{\nu\mu}(x)] \quad (20)$$

și vom lua ca **număr de condiționare**

$$(\text{cond } f)(x) = \|\Gamma(x)\|. \quad (21)$$

# Condiționarea unei probleme

**Altfel.**

$$\|\Delta y\| = \|f(x + \Delta x) - f(x)\| \leq \|\Delta x\| \left\| \frac{\partial f}{\partial x} \right\|$$

unde

$$J(x) = \frac{\partial f}{\partial x} = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} & \cdots & \frac{\partial f_1}{\partial x_m} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} & \cdots & \frac{\partial f_2}{\partial x_m} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_n}{\partial x_1} & \frac{\partial f_n}{\partial x_2} & \cdots & \frac{\partial f_n}{\partial x_m} \end{bmatrix} \in \mathbb{R}^n \times \mathbb{R}^m \quad (22)$$

este matricea jacobiană a lui  $f$

$$\frac{\|\Delta y\|_\infty}{\|y\|_\infty} \leq \frac{\|x\|_\infty \left\| \frac{\partial f}{\partial x} \right\|_\infty}{\|f(x)\|_\infty} \cdot \frac{\|\Delta x\|_\infty}{\|x\|_\infty}. \quad (23)$$

- Pentru  $m = n = 1$  și  $x \neq 0, y \neq 0$

$$(\text{cond } f)(x) = \left| \frac{xf'(x)}{f(x)} \right|.$$

- Dacă  $x = 0 \wedge y \neq 0$  se consideră eroarea absolută pentru  $x$  și eroarea relativă pentru  $y$

$$(\text{cond } f)(x) = \left| \frac{f'(x)}{f(x)} \right|;$$

- Pentru  $y = 0 \wedge x \neq 0$  se ia eroarea absolută pentru  $y$  și eroarea relativă pentru  $x$
- Pentru  $x = y = 0$ , se iau erorile absolute

$$(\text{cond } f)(x) = f'(x).$$

- Număr de condiționare absolută al unei probleme diferențiabile  $f$  în  $x$ :

$$\hat{\kappa} = \sup_{\delta x} \frac{\|\delta f\|}{\|\delta x\|} = \|J(x)\|$$

unde  $J(x) = [J_{ij}] = [\partial f_i / \partial x_j]$ , este jacobianul, iar norma este indusă de normele lui  $\delta f$  și  $\delta x$

- în cazul unidimensional

$$\hat{\kappa} = |f'(x)|.$$

# Exemple

- **Exemplu:** Funcția  $f(x) = \alpha x$

- număr de condiționare absolută  $\hat{\kappa} = \|J\| = \alpha$
- număr de condiționare relativă  $(\text{cond } f)(x) = \frac{\|J\|}{\|f(x)\|/\|x\|} = \frac{\alpha}{\alpha x/x} = 1$

- **Exemplu:** Funcția  $f(x) = \sqrt{x}$

- număr de condiționare absolută  $\hat{\kappa} = \|J\| = \frac{1}{2\sqrt{x}}$
- număr de condiționare relativă  
 $(\text{cond } f)(x) = \frac{\|J\|}{\|f(x)\|/\|x\|} = \frac{1/(2\sqrt{x})}{\sqrt{x}/x} = \frac{1}{2}$

- **Exemplu:** Funcția  $f(x) = x_1 - x_2$  (cu norma  $\infty$ )

- număr de condiționare absolută  $\hat{\kappa} = \|J\| = \|(-1, 1)^T\| = 2$
- număr de condiționare relativă

$$(\text{cond } f)(x) = \frac{\|J\|}{\|f(x)\|/\|x\|} = \frac{2}{|x_1 - x_2| \max\{|x_1|, |x_2|\}}$$

- prost condiționată dacă  $x_1 \approx x_2$  (anulare)

- Pentru o funcție dată  $g(n)$  vom nota cu  $\Theta(g(n))$  mulțimea de funcții

$$\Theta(g(n)) = \{f(n) : \exists c_1, c_2, n_0 > 0 \ 0 \leq c_1 g(n) \leq f(n) \leq c_2 g(n) \\ \forall n \geq n_0\}.$$

- Scriem  $f(n) = \Theta(g(n))$  pentru a indica  $f(n) \in \Theta(g(n))$ . Spunem că  $g(n)$  este o *margine asimptotică strânsă* (*asymptotically tight bound*) pentru  $f(n)$ .
- Definiția mulțimii  $\Theta(g(n))$  necesită ca fiecare membru al ei să fie *asimptotic nenegativ*, adică  $f(n) \geq 0$  când  $n$  este suficient de mare.

- Pentru o funcție dată  $g(n)$  vom nota cu  $O(g(n))$  mulțimea de funcții

$$O(g(n)) = \{f(n) : \exists c, n_0 \ 0 \leq f(n) \leq cg(n), \ \forall n \geq n_0\}.$$

- *margină asimptotică superioară*
- Pentru a indica faptul că  $f(n)$  este un membru al lui  $O(g(n))$  scriem  $f(n) = O(g(n))$ .
- Observăm că  $f(n) = \Theta(g(n)) \implies f(n) = O(g(n))$ , sau  $\Theta(g(n)) \subseteq O(g(n))$
- Una dintre proprietățile ciudate ale notației este aceea că  $n = O(n^2)$ .

- Pentru o funcție dată  $g(n)$  vom nota prin  $\Omega(g(n))$  mulțimea de funcții

$$\Omega(g(n)) = \{f(n) : \exists c, n_0 \ 0 \leq cg(n) \leq f(n), \ \forall n \geq n_0\}.$$

- *margină asimptotică inferioară*
- Din definițiile notațiilor asimptotice se obține imediat:

$$f(n) = \Theta(g(n)) \iff f(n) = O(g(n)) \wedge f(n) = \Omega(g(n)).$$



- Spunem că funcțiile  $f$  și  $g : \mathbb{N} \longrightarrow \mathbb{R}$  sunt *asimptotic echivalente*, notație  $\sim$  dacă

$$\lim_{n \rightarrow \infty} \frac{f(n)}{g(n)} = 1.$$

- Extinderea notațiilor asimptotice la mulțimea numerelor reale este naturală. De exemplu  $f(t) = O(g(t))$  înseamnă că există o constantă pozitivă  $C$  astfel încât pentru orice  $t$  suficient de apropiat de o limită subînțeleasă (de exemplu  $t \rightarrow \infty$  sau  $t \rightarrow 0$ ) avem

$$|f(t)| \leq Cg(t). \quad (24)$$

- Considerăm un *algoritm*  $\tilde{f}$  pentru *problema*  $f$
- Un calcul  $\tilde{f}(x)$  are *eroarea absolută*  $\|\tilde{f}(x) - f(x)\|$  și *eroarea relativă*

$$\frac{\|\tilde{f}(x) - f(x)\|}{\|f(x)\|}$$

- Algoritmul este **precis** dacă (pentru orice  $x$ )

$$\frac{\|\tilde{f}(x) - f(x)\|}{\|f(x)\|} = O(\text{eps})$$

unde  $O(\text{eps})$  este “de ordinul eps” (vezi slide-ul următor)

- Constanta din  $O(\text{eps})$  poate fi foarte mare pentru multe probleme, căci datorită erorilor de rotunjire nu utilizăm nici chiar un  $x$  corect.

# Detalii asupra notațiilor asimptotice

- Notația  $\varphi(t) = O(\psi(t))$  înseamnă că există o constantă  $C$  a.î. pentru  $t$  apropiat de o limită (de obicei 0 sau  $\infty$ ),  $|\varphi(t)| \leq C\psi(t)$
- **Exemplu:**  $\sin^2 t = O(t^2)$  când  $t \rightarrow 0$  înseamnă  $|\sin^2 t| \leq Ct^2$  pentru un anumit  $C$
- Dacă  $\varphi$  depinde de variabile adiționale, notația

$$\varphi(s, t) = O(\psi(t)) \quad \text{uniform în } s$$

înseamnă că există o constantă  $C$  a.î.  $|\varphi(s, t)| \leq C\psi(t)$  pentru orice  $s$

- **Exemplu:**  $(\sin^2 t)(\sin^2 s) = O(t^2)$  uniform când  $t \rightarrow 0$ , dar nu dacă  $\sin^2 s$  este înlocuit cu  $s^2$
- În margini de forma  $\|\tilde{x} - x\| \leq C\kappa(A)\epsilon \|x\|$ ,  $C$  nu depinde de  $A$  sau  $b$ , dar poate depinde de dimensiunea  $m$

- Un algoritm  $\tilde{f}$  pentru problema  $f$  este stabil dacă pentru orice  $x$  există un  $\tilde{x}$  cu proprietatea

$$\frac{\|\tilde{x} - x\|}{\|x\|} = O(\text{eps})$$

a.î.

$$\frac{\|\tilde{f}(x) - f(x)\|}{\|f(x)\|} = O(\text{eps})$$

- Un algoritm  $\tilde{f}$  pentru problema  $f$  este **stabil** dacă pentru orice  $x$  există un  $\tilde{x}$  cu proprietatea

$$\frac{\|\tilde{x} - x\|}{\|x\|} = O(\text{eps})$$

a.î.

$$\frac{\|\tilde{f}(x) - f(x)\|}{\|f(x)\|} = O(\text{eps})$$

- “Răspuns aproape corect la problemă aproape exactă”

# Stabilitatea

- Un algoritm  $\tilde{f}$  pentru problema  $f$  este **stabil** dacă pentru orice  $x$  există un  $\tilde{x}$  cu proprietatea

$$\frac{\|\tilde{x} - x\|}{\|x\|} = O(\text{eps})$$

a.î.

$$\frac{\|\tilde{f}(x) - f(x)\|}{\|f(x)\|} = O(\text{eps})$$

- “Răspuns aproape corect la problemă aproape exactă”
- Un algoritm  $\tilde{f}$  pentru problema  $f$  este **regresiv stabil** dacă pentru orice  $x$  există un  $\tilde{x}$  cu proprietatea

$$\frac{\|\tilde{x} - x\|}{\|x\|} = O(\text{eps})$$

a.î.

$$\tilde{f}(x) = f(\tilde{x}).$$

- Un algoritm  $\tilde{f}$  pentru problema  $f$  este **stabil** dacă pentru orice  $x$  există un  $\tilde{x}$  cu proprietatea

$$\frac{\|\tilde{x} - x\|}{\|x\|} = O(\text{eps})$$

a.î.

$$\frac{\|\tilde{f}(x) - f(x)\|}{\|f(x)\|} = O(\text{eps})$$

- “Răspuns aproape corect la problemă aproape exactă”
- Un algoritm  $\tilde{f}$  pentru problema  $f$  este **regresiv stabil** dacă pentru orice  $x$  există un  $\tilde{x}$  cu proprietatea

$$\frac{\|\tilde{x} - x\|}{\|x\|} = O(\text{eps})$$

a.î.

$$\tilde{f}(x) = f(\tilde{x}).$$

- “Răspuns corect la problemă aproape exactă”

- Cele două axiome ale AVF implică stabilitatea regresivă a operației  $\odot$

(1)  $\forall x \in \mathbb{R}, \exists \epsilon$  cu  $|\epsilon| \leq \text{eps}$  a.î.  $\text{fl}(x) = x(1 + \epsilon)$

(2) Pentru orice NVF  $x, y$ , există  $\epsilon$  cu  $|\epsilon| \leq \text{eps}$  a.î.  
 $x \odot y = (x \circ y)(1 + \epsilon)$

- **Exemplu:** Scăderea  $f(x_1, x_2) = x_1 - x_2$  cu algoritmul

$$\tilde{f}(x_1, x_2) = \text{fl}(x_1) \ominus \text{fl}(x_2)$$

- (1) implică existența  $|\epsilon_1|, |\epsilon_2| \leq \text{eps}$  a.î.

$$\text{fl}(x_1) = x_1(1 + \epsilon_1), \quad \text{fl}(x_2) = x_2(1 + \epsilon_2)$$



(continuarea exemplului)

- (2) implică existența  $|\epsilon_3| \leq \text{eps}$  a.î.

$$\text{fl}(x_1) \ominus \text{fl}(x_2) = (\text{fl}(x_1) - \text{fl}(x_2))(1 + \epsilon_3)$$

- Combinând, rezultă existența  $|\epsilon_4|, |\epsilon_5| \leq 2\text{eps} + O(\text{eps}^2)$  a.î.

$$\begin{aligned}\text{fl}(x_1) \ominus \text{fl}(x_2) &= (x_1(1 + \epsilon_1) - x_2(1 + \epsilon_2))(1 + \epsilon_3) \\ &= x_1(1 + \epsilon_1)(1 + \epsilon_3) - x_2(1 + \epsilon_2)(1 + \epsilon_3) \\ &= x_1(1 + \epsilon_4) - x_2(1 + \epsilon_5)\end{aligned}$$

- Deci,  $\text{fl}(x_1) - \text{fl}(x_2) = \tilde{x}_1 - \tilde{x}_2$

- **Exemplu:** Produsul  $f(x, y) = x^*y$  calculat cu  $\otimes$  și  $\oplus$  este regresiv stabil

- **Exemplu:** Produsul  $f(x, y) = x^*y$  calculat cu  $\otimes$  și  $\oplus$  este regresiv stabil
- **Exemplu:** Produsul exterior  $f(x, y) = xy^*$  calculat cu  $\otimes$  nu este regresiv stabil (în afară de cazul când  $\tilde{f}$  are rangul 1)

- **Exemplu:** Produsul  $f(x, y) = x^*y$  calculat cu  $\otimes$  și  $\oplus$  este regresiv stabil
- **Exemplu:** Produsul exterior  $f(x, y) = xy^*$  calculat cu  $\otimes$  nu este regresiv stabil (în afară de cazul când  $\tilde{f}$  are rangul 1)
- **Exemplu:**  $f(x) = x + 1$  calculat cu  $\tilde{f}(x) = \text{fl}(x) \oplus 1$  nu este regresiv stabil (considerăm  $x \approx 0$ )

- **Exemplu:** Produsul  $f(x, y) = x^*y$  calculat cu  $\otimes$  și  $\oplus$  este regresiv stabil
- **Exemplu:** Produsul exterior  $f(x, y) = xy^*$  calculat cu  $\otimes$  nu este regresiv stabil (în afară de cazul când  $\tilde{f}$  are rangul 1)
- **Exemplu:**  $f(x) = x + 1$  calculat cu  $\tilde{f}(x) = \text{fl}(x) \oplus 1$  nu este regresiv stabil (considerăm  $x \approx 0$ )
- **Exemplu:**  $f(x, y) = x + y$  calculat cu  $\tilde{f}(x, y) = \text{fl}(x) \oplus \text{fl}(y)$  este regresiv stabil

## Teoremă (Precizia unui algoritm regresiv stabil)

*Daca se utilizează un algoritm regresiv stabil pentru a rezolva problema  $f$  cu numărul de condiționare  $\kappa$ , eroarea relativă satisface*

$$\frac{\|\tilde{f}(x) - f(x)\|}{\|f(x)\|} = O((\text{cond } f)(x)\text{eps})$$







## Demonstrație.



Stabilitatea regresivă înseamnă  $\tilde{f}(x) = f(\tilde{x})$ , pentru un anumit  $\tilde{x}$  a. î.  $\frac{\|\tilde{x} - x\|}{\|x\|} = O(\text{eps})$ . Definiția numărului de condiționare ne dă

$$\frac{\|\tilde{f}(x) - f(x)\|}{\|f(x)\|} = ((\text{cond } f)(x) + o(1)) \frac{\|\tilde{x} - x\|}{\|x\|}$$

unde  $o(1) \rightarrow 0$  la fel ca  $\text{eps} \rightarrow 0$ . Combinând aceste două se obține rezultatul dorit. □

# Bibliografie I

-  James Demmel, *Applied Numerical Linear Algebra*, SIAM, Philadelphia, 1997.
-  W. Gautschi, *Numerical Analysis. An Introduction*, Birkhäuser, Basel, 1997.
-  D. Goldberg, *What every computer scientist should know about floating-point arithmetic*, Computing Surveys **23** (1991), no. 1, 5–48.
-  Nicholas J. Higham, *Accuracy and Stability of Numerical Algorithms*, SIAM, Philadelphia, 1996.
-  M. L. Overton, *Numerical Computing with IEEE Floating Point Arithmetic*, SIAM, Philadelphia, 2001.
-  J. Stoer, R. Burlisch, *Introduction to Numerical Analysis*, 2nd ed., Springer Verlag, 1992.

-  C. Überhuber, *Computer-Numerik*, vol. 1, 2, Springer Verlag, Berlin, Heidelberg, New-York, 1995.
-  C. Ueberhuber, *Numerical Computation. Methods, Software and Analysis*, vol. I, II, Springer Verlag, Berlin, Heidelberg, New York, 1997.