Interogări distribuite

```
SELECT AVG(E.age)
FROM Employees E
WHERE E.salary > 3000
  AND E.salary < 7000
```

Fragmentare orizontală:

Înregistrările cu *salary* < 5000 la Shanghai şi *salary* >= 5000 la Tokyo.

- Se calculează SUM(*age*), COUNT(*age*) pe ambele servere
- Dacă WHERE conține doar E.*salary*>6000, interogarea se poate executa pe un singur server.

Interogări distribuite

```
SELECT AVG(E.age)
FROM Employees E
WHERE E.salary > 3000
  AND E.salary < 7000
```

Fragmentare verticală:

title şi *salary* la Shanghai, *ename* şi *age* la Tokyo, *id* fiind prezent pe ambele servere.

- Trebuie reconstruită tabela prin intermediul unui *join* pe *id*, iar apoi se evaluează interogarea.

- Replicare: Tabela *Employees* e copiată pe ambele servere.
  - Alegerea site-ului pe care se execută interogarea se face în funcție de costurile locale şi costurile de trasfer.

Join-uri distribuite

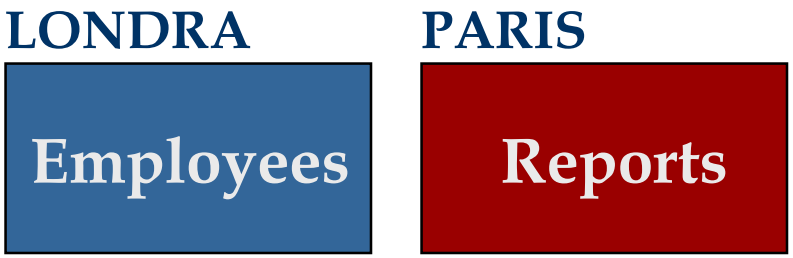

Employees

500 pagini,

80 înregistrări pe pagină

Reports

1000 pagini

100 înregistrări pe pagină

Fetch as Needed

- *Page-oriented nested loops*, *Employees* ca tabelă externă (pentru fiecare pagină din *Employees* se aduc toate paginile din *Reports* de la Paris):
  - **Cost:** 500 D + 500 * 1000 (D+S), unde **D** este costul de citire/salvare a paginilor; **S** costul de transfer al paginilor.
  - Dacă interogarea nu s-a lansat de la Londra, atunci trebui adăugat costul de transfer al rezultatului către clientul care a transmis interogarea.
- Se poate utiliza si INL (*Indexed Nested Loops*) la Londra, aducând din tabela *Reports* doar înregistrările ce se potrivesc.

Ship to One Site

- Transferă tabela *Reports* la Londra
  - Cost: 1000 S + 4500 D (*Sort-Merge Join*; cost = 3*(500+1000))
  - Dacă dimensiunea rezultatului este mare, ambele relații ar putea fi transferate către serverul ce a inițiat interogarea iar join-ul este implementat acolo
- Transferă tabela *Employees* la Paris
  - Cost: 500 S + 4500 D

Semijoin

- La Londra se execută proiecția tabelei *Employees* pe câmpul (câmpurile) folosite în join şi rezultatul se transferă la Paris.
- La Paris se execută join între proiecția lui *Employees* şi tabela *Reports*.
  - Rezultatul se numeşte **reducția** lui *Reports* relativ la *Employees* .
- Se transferă reducția lui *Reports* la Londra
- La Londra, se execută join între *Employees* şi reducția lui *Reports*.

Bloomjoin

- La Londra se construieşte un vector de biți de dimensiune k:
  - Folosind o funcție de dispersie, se împart valorile câmpului de join în partiții de la 0 la k-1.
  - Dacă funcția aplicată câmpului returnează *i*, se setează bitul *i* cu 1 (*i* de la 0 la k-1).
  - Se transferă vectorul de biți la *Paris*.

Bloomjoin (cont)

- La Paris, folosim similar funcția de dispersie. Dacă pentru un câmp se obține un *i* căruia în vector ii corespunde 0 , se elimină acea înregistrare din rezultat
  - Rezultatul se numeşte **reducție** a tabelei *Reports* în funcție de *Employees*.
- Se transferă reducția la Londra.
- La Londra se face join-ul dintre *Employees* şi varianta redusă a lui *Reports*.

Optimizarea interogărilor

11

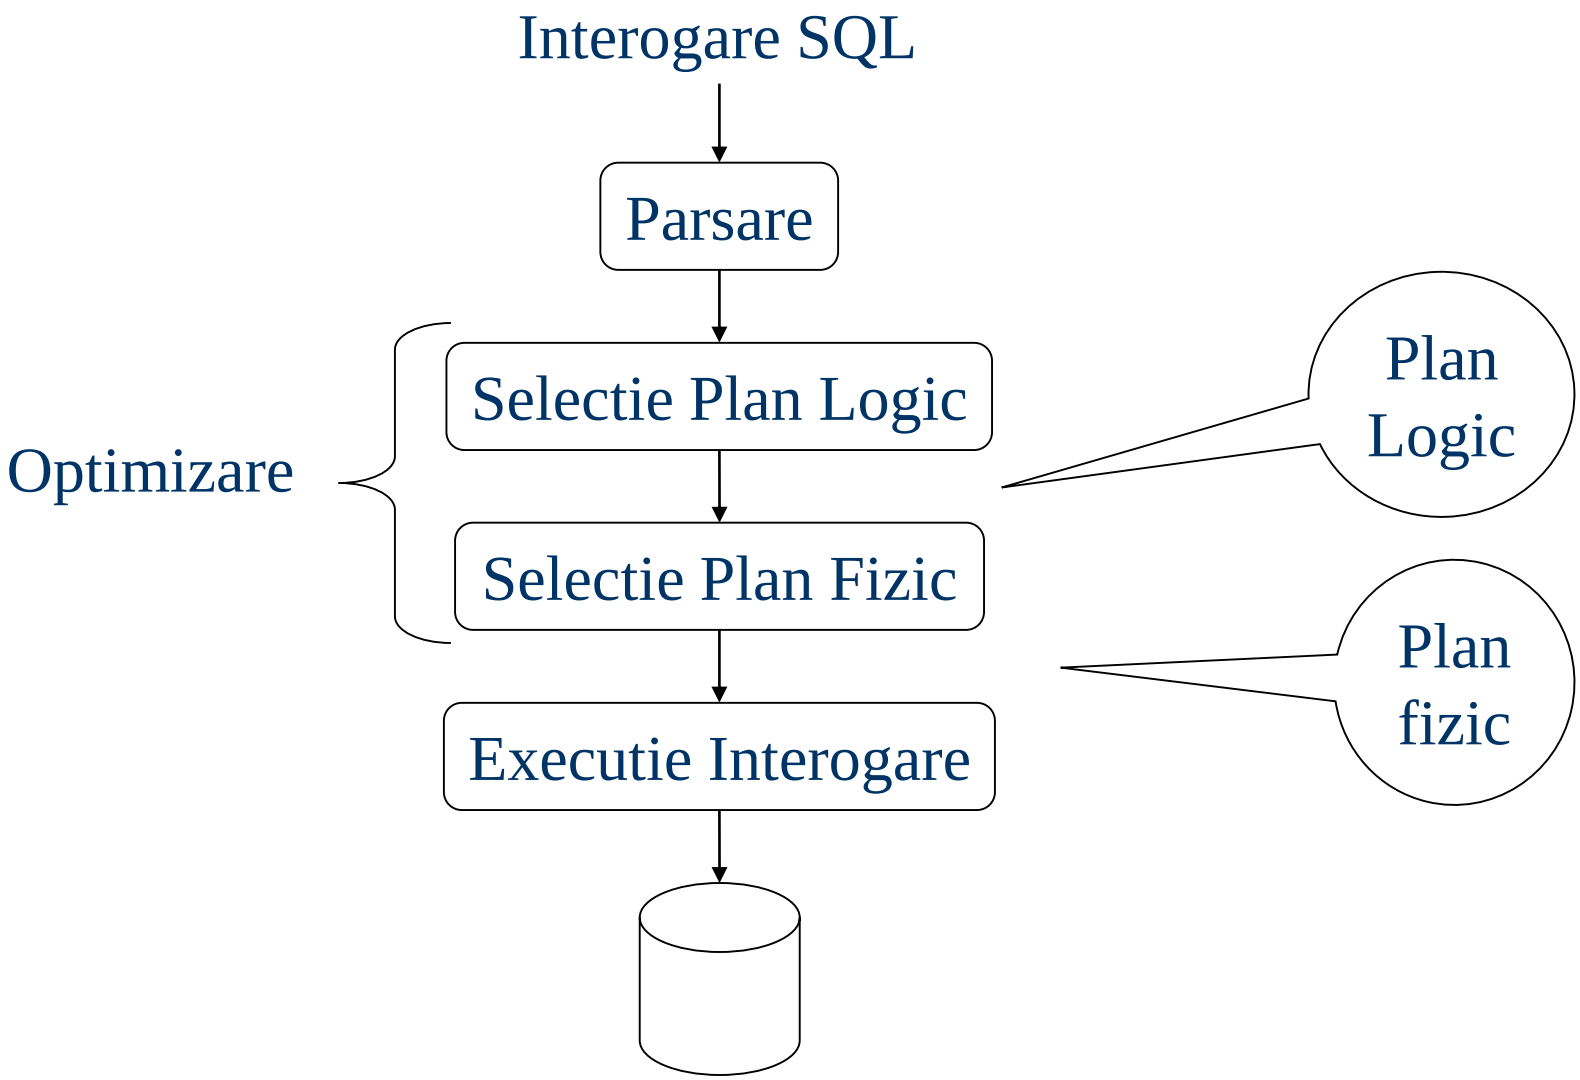
Interogare SQL
Parsare
Selectie Plan Logic
Optimizare
Selectie Plan Fizic
Executie Interogare
Plan Logic
Plan fizic

Executarea interogărilor

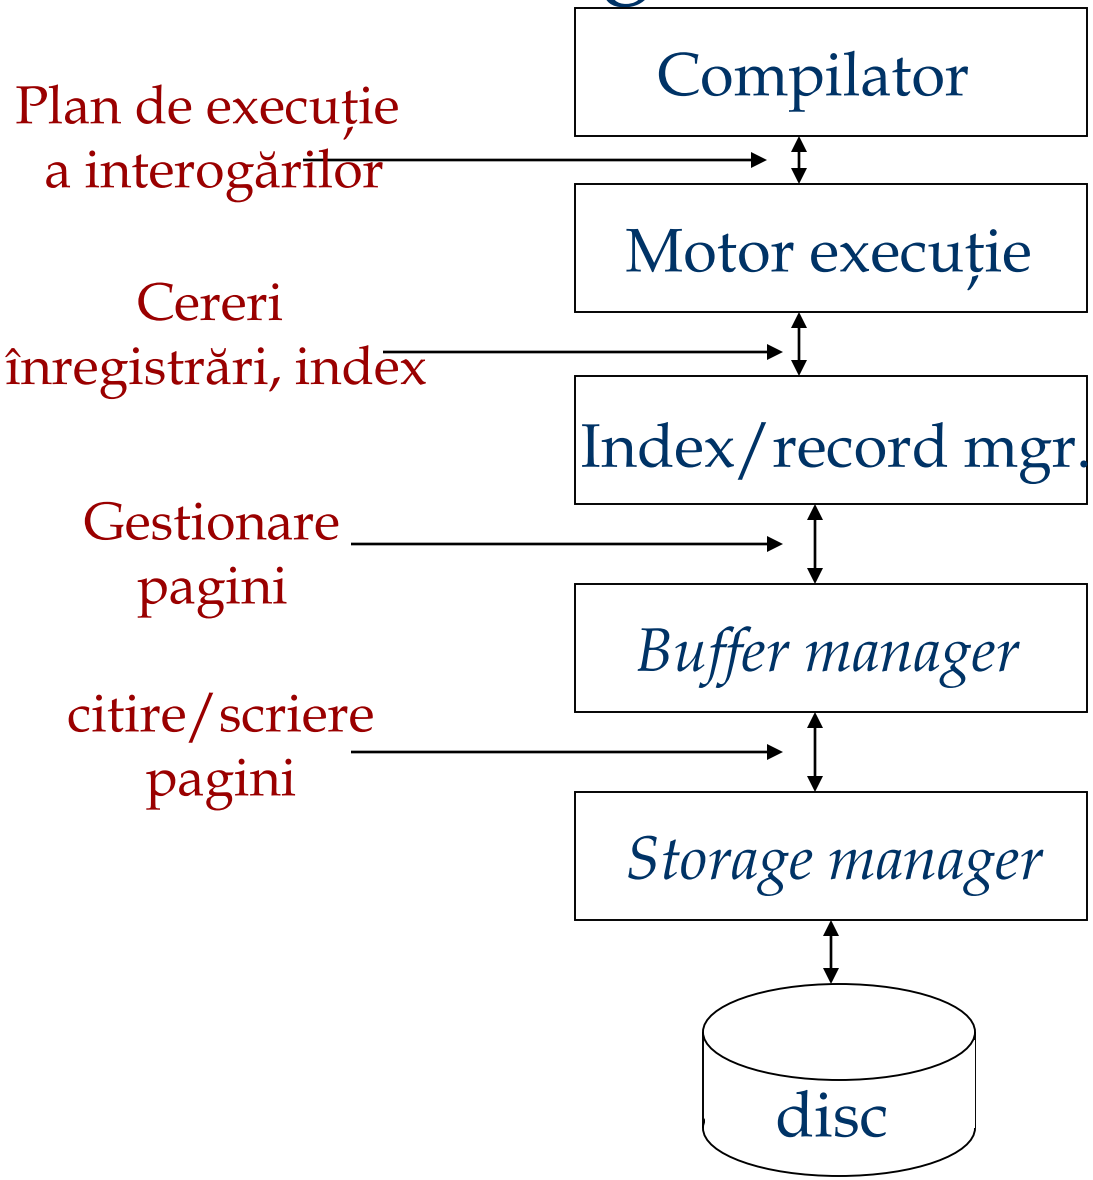

Structura folosită în exemple

Students (*sid*: integer, *sname*: string, *age*: integer)
Courses (*cid*: integer, *name*: string, *location*: string)
Evaluations (*sid*: integer, *cid*: integer, *day*: date, *grade*: integer)

- *Students*:
  - Fiecare înregistrare are o lungime de 50 bytes.
  - 80 înregistrări pe pagină, 500 pagini.
- *Courses*:
  - Lungime înregistrare 50 bytes,
  - 80 înregistrări pe pagină, 100 pagini.
- *Evaluations*:
  - Lungime înregistrare 40 bytes,
  - 100 înregistrări pe pagină, 1000 pagini.

Planurile de execuție ale interogărilor

```
SELECT  E1.date
FROM    Evaluations E1, Students S1
WHERE   E1.sid=S1.sid AND
        E1.grade > 8
```

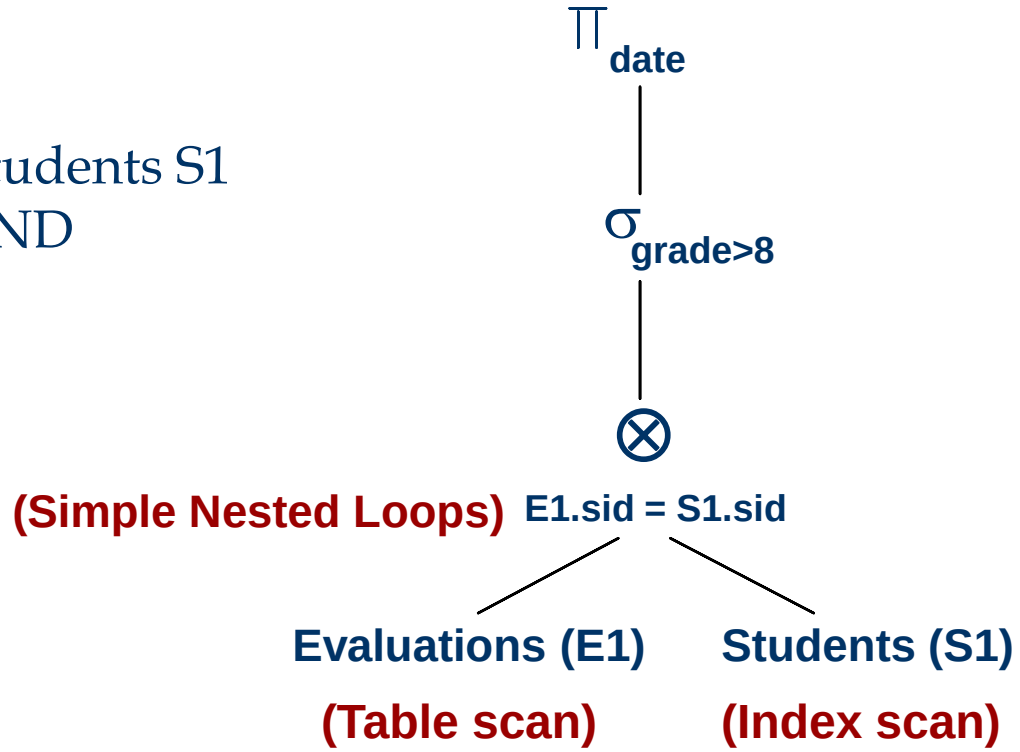

Planul interogării:

- arbore logic
- se specifică o decizie de implementare la fiecare nod
- planificarea operațiilor

Frunzele planului de executie: scanări

- Table scan: iterează prin înregistrările tabelei.
- Index scan: accesează înregistrările tabelei prin index
- Sorted scan: accesează înregistrările tabelei dupa ce aceasta a fost sortată în prealabil.
- Cum se combină operațiile?
  - Modelul iterator. Fiecare operație e implementată cu 3 funcții:
    - *Open*: inițializări / pregătește structurile de date
    - *GetNext*: returnează următoarea înregistrare din rezultat
    - *Close*: finalizează operația / eliberează memoria

    => permite lucrul în pipeline!
  - Modelul materializat (*data-driven*)
    - Uneori modul de operare a ambelor modele e identic (exemplu: *sorted scan*).

Proces de optimizare a interogărilor

- Se transformă interogarea SQL într-un arbore logic:
  - identifică blocurile distincte (*view*-uri, sub-interogări).
- Se rescrie interogarea:
  - se aplica transformări algebrice pentru a obține un plan mai puțin costisitor.
  - se unesc blocuri de date și/sau se mută predicate între blocuri.
- Se optimizează fiecare bloc: secvențele de execuție a join-urilor.

Proces de optimizare a interogărilor

- *Plan*: *Arbore format din operatori algebrici relaționali*
  - Pentru fiecare operator este identificat un algoritm de execuție
  - Fiecare operator are (în general) implementată o interfață *`pull'*.
- Probleme:
  - Ce planuri se iau în considerare?
  - Cum se estimează costul unui plan?
- Se implementează algoritmi de identificare a planurilor cele mai puțin costisitoare:
  - Ideal: se dorește obținerea celui mai bun plan.
  - Practic: se elimină planurile cele mai costisitoare!

System R Optimizer

- Impact:
  - Cel mai utilizat algoritm;
  - Funcționează bine pentru < 10 *join*-uri.

- Estimare cost: aproximări, aproximări, aproximări...
  - Statistici, actualizate în catalogul bazei de date, folosite la estimarea costului operațiilor și a dimensiunii rezultatelor.
  - Combinație între costul CPU și costurile de citire/scriere.

System R Optimizer

- Nu se estimeaza toate planurile!
  - Sunt considerate doar planurile *left-deep join*
    - Aceste planuri permit ca rezultatul unui operator sa fie transferat în *pipeline* către următorul operator fără stocarea temporară a relației.
  - Se exclude produsul cartezian

Exemplu

```
SELECT  S.sname
FROM  Evaluations E, Students S
WHERE  E.sid=S.sid AND
    E.cid=100 AND S.age>22
```

RA Tree:

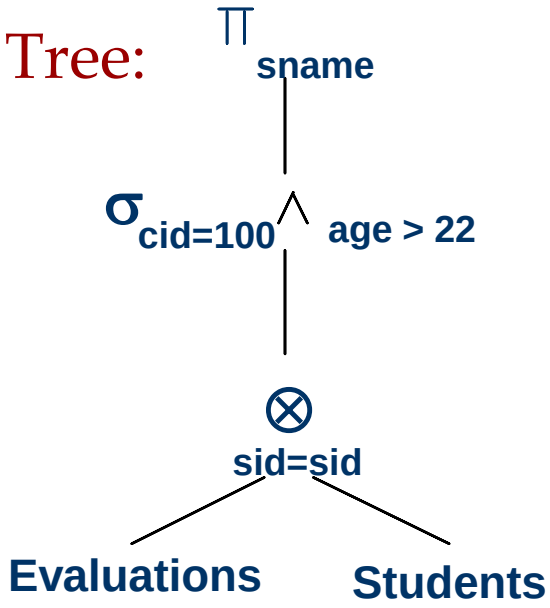

Plan:

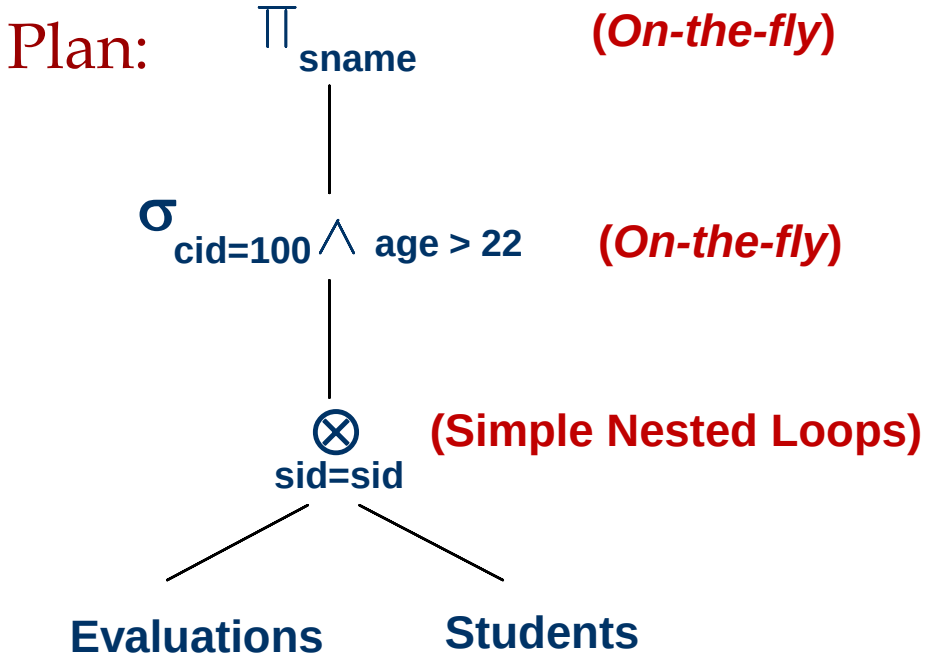

- Cost: 500+500*1000 I/Os
- Plan inadecvat, cost f mare!

- *Scopul optimizarii:* căutarea de planuri mai eficiente ce calculează același răspuns.

Plan alternativ 1

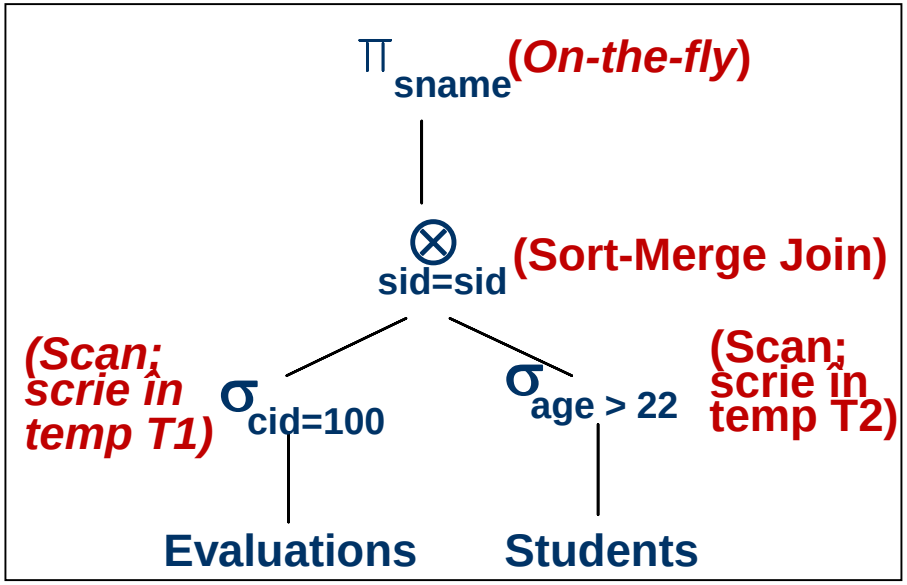

- ***Diferența esențială:***

  poziția operatorilor de selecție.

- Costul planului (presupunem că sunt 5 pagini în buffer):
  - Scan *Evaluations* (1000) + memorează temp T1 (10 pag, dacă avem 100 cursuri și distribuție uniformă). – *total 1010 I/Os*
  - Scan *Students* (500) + memorează temp T2 (250 pag, dacă avem 10 vârste). – *total 750 I/Os*
  - Sortare T1 (2*2*10), sortare T2 (2*3*250), interclasare (10+250) – *total 1800 I/Os*
  - Total: 3560 pagini I/Os.

Plan alternativ 1

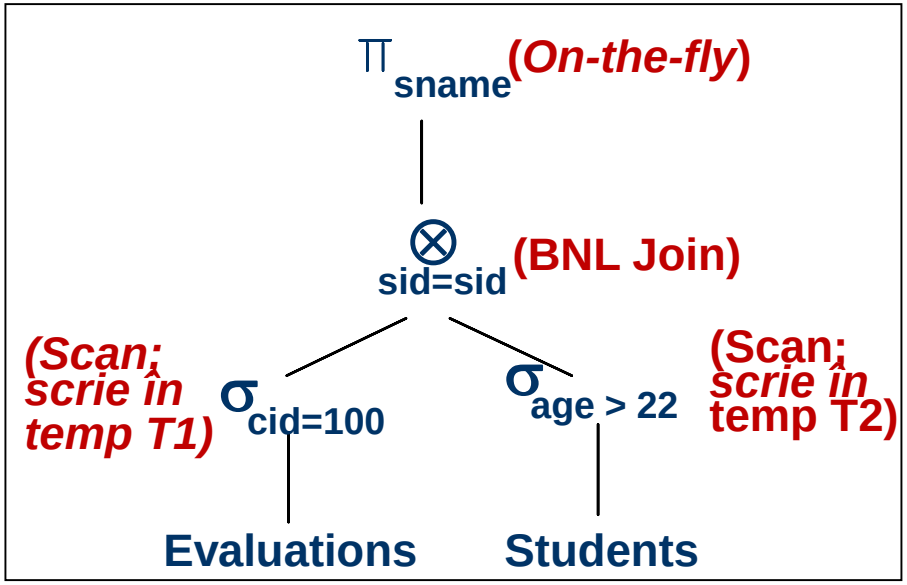

- ***Diferența esențială:***

  poziția operatorilor de selecție.

- Costul planului (presupunem că sunt 5 pagini în buffer):

- Dacă se foloseste BNL join:
  - cost join = 10+4*250,
  - cost total = 2770.

- Dacă `împingem' proiecțiile:
  - T1 rămâne cu *sid*, T2 rămâne cu *sid* şi *sname*:
  - T1 încape în 3 pagini, costul BNL este sub 250 pagini, total < 2000.

Plan alternativ 2

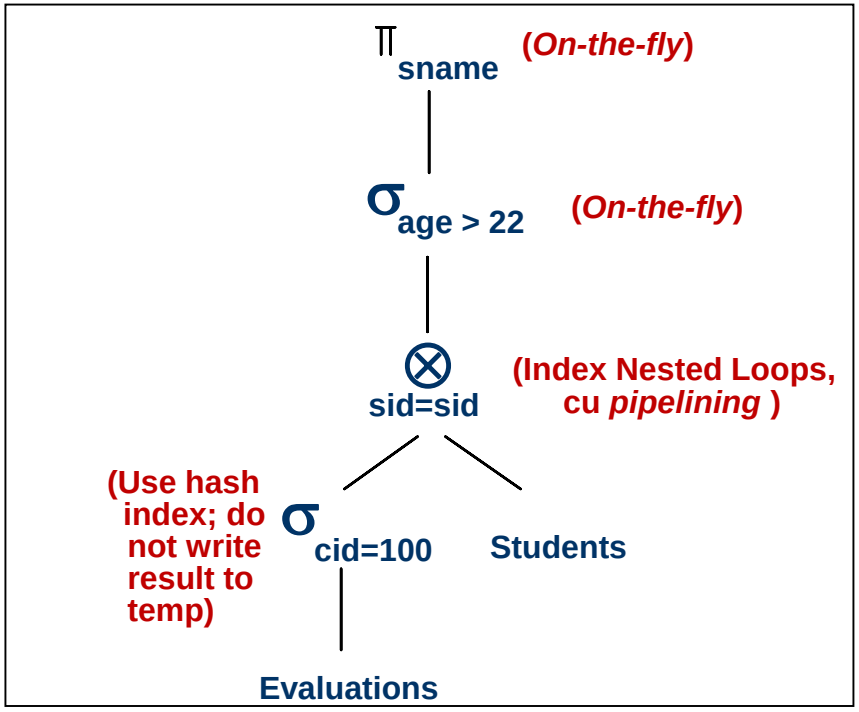

- Cu index grupat pe *cid* din *Evaluations*, avem 100,000/100 = 1000 tupluri în 1000/100 = 10 pagini.
- INL cu ***pipelining*** (rezultatul nu e materializat).
  - Se elimină câmpurile inutile din output.
- Coloana *sid* e cheie pentru *Students*.
  - Cel mult o "potrivire", index grupat pe *sid* e OK.
- Decizia de a nu „împinge" selecția *age>22* mai repede e dată de disponibilitatea indexului pe *sid* al *Students*.

Cost: Selecție pe Evaluations (10 I/Os); pentru fiecare obținem înregistrările din *Students* (1000*1.2); total *1210 I/Os*.

Unitatea de optimizare: *bloc Select*

- O interogare SQL este descompusă într-o colecție de *blocuri Select* care sunt optimizate separat.

- *Blocurile Select* imbricate sunt de obicei tratate ca apeluri de sub-rutine (câte un apel pentru fiecare înregistrare din blocul Select extern)

```
SELECT  S.sname
FROM  Students S
WHERE  S.age IN
     (SELECT  MAX (S2.age)
      FROM  Students S2
      GROUP BY  S2.sname)
```

Bloc extern *Bloc imbricat*

Pentru fiecare bloc, planurile considerate sunt:

- Toate metodele disponibile de acces, pt fiecare tabelă din FROM
- Toate planurile *left-deep join trees* (adică, toate modurile secvențiale de *join* ale tabelelor, considerând toate permutările de tabele posibile)

Estimarea costului

- Se estimează costul fiecărui plan considerat:
  - Trebuie estimat *costul* fiecărui operator din plan
    - Depinde de cardinalitatea tabelelor de intrare
    - Modul de estimarea al costurilor a fost discutat în cursurile precedente (scanare tabele, join-uri, etc.)
  - Trebuie estimată *dimensiunea rezultatului* pentru fiecare operație a arborelui!
    - Se utilizează informații despre relațiile de intrare
    - Pentru selecții şi join-uri, se consideră predicatele ca fiind independente.
- Algoritmul System R
  - Inexact, dar cu rezultate bune în practică.
  - În prezent există metode mai sofisticate

Echivalențe în algebra relațională

- Permit alegerea unei ordini diferite a join-urilor şi `*împingerea*' selecțiilor şi proiecțiilor în fața join-urilor.

- *Selecții*: $\sigma_{c1\wedge\ldots\wedge cn}(R) \equiv \sigma_{c1}(\ldots(\sigma_{cn}(R)))$ (*Cascadă*)

  $\sigma_{c1}(\sigma_{c2}(R)) \equiv \sigma_{c2}(\sigma_{c1}(R))$ (*Comutativitate*)

- *Proiecții*: $\pi_{a1}(R) \equiv \pi_{a1}(\ldots(\pi_{an}(R)))$ (*Cascadă*)

- *Join*: $R \otimes (S \otimes T) \equiv (R \otimes S) \otimes T$ (*Asociativitate*)

  $(R \otimes S) \equiv (S \otimes R)$ (*Comutativitate*)

  $\rightarrow$ $R \otimes (S \otimes T) \equiv (T \otimes R) \otimes S$

Alte echivalențe

- A proiecție se comută doar cu o selecție ce utilizează câmpurile ce apar în proiecție.
- Selecția dintre câmpurile ce aparțin tabelelor implicate într-un produs cartezian converteşte produsul cartezian intr-un *join*.
- O selecție doar pe atributele lui R comută cu R ⊗ S. (adică, σ (R ⊗ S) ≡ σ (R) ⊗ S)
- Similar, dacă o proiecție urmează unui join R ⊗ S, putem să o `*împingem*' în fața join-ului păstrând doar câmpurile lui R (şi S) care sunt necesare pentru join sau care apar în lista proiecției.

Enumerarea planurilor alternative

- Sunt luate în considerare două cazuri:
  - Planuri cu o singură tabelă
  - Planuri cu tabele multiple

- Pentru interogările ce implică o singură tabelă, planul conține o combinație de selecturi, proiecții şi operatori de agregare:
  - Sunt considerate toate metodele de acces şi este păstrată cea cu cel mai mai mic cost estimat.
  - Mai mulți operatori sunt executați deodată (în *pipeline*)

Estimări de cost pentru planuri bazate pe o tabelă

- Indexul I pt cheia primară implicată într-o selecție:
  - *Costul e Height(I)+1 pt un arbore B+, sau 1.2+1 pt hash index.*
- Index grupat I pe câmpurile implicate în una sau mai multe selecții:
  - *(NPages(I)+NPages(R)) * produs al FR pt fiecare selecție*
- Index negrupat I pe câmpurile implicate în una sau mai multe selecții:
  - *(NPages(I)+NTuples(R)) * produs al FR pt fiecare selecție.*
- Scanare secvențială a tabelei:
  - *NPages(R).*

Exemplu

```
SELECT S.sid
FROM Students S
WHERE S.age=20
```

- Dacă există index pt. *age*:
  - (1/NKeys(I)) * NTuples(R) = (1/10) * 40000 înreg. returnate
  - Index grupat: (1/NKeys(I)) * (NPages(I)+NPages(R)) = (1/10) * (50+500) pagini returnate.
  - Index negrupat: (1/NKeys(I)) * (NPages(I)+NTuples(R)) = (1/10) * (50+40000) pagini returnate.

- Dacă se scanează tabela :
  - Sunt citite toate paginile (500).

Interogări pe tabele multiple

- System R consideră doar arborii *left-deep join*.
  - Pe măsură ce numărul de join-uri creşte , numărul de planuri alternative este tot mai semnificativ; *este necesară restricționarea spațiului de căutare.*
  - Arborii *left-deep* ne permit generarea tuturor planurilor ce suportă *pipeline* complet.

    - Rezultatele intermedare nu sunt salvate în tabele temporare.

    - Nu toți arborii *left-deep* suportă *pipeline* complet (ex. *SM join*).

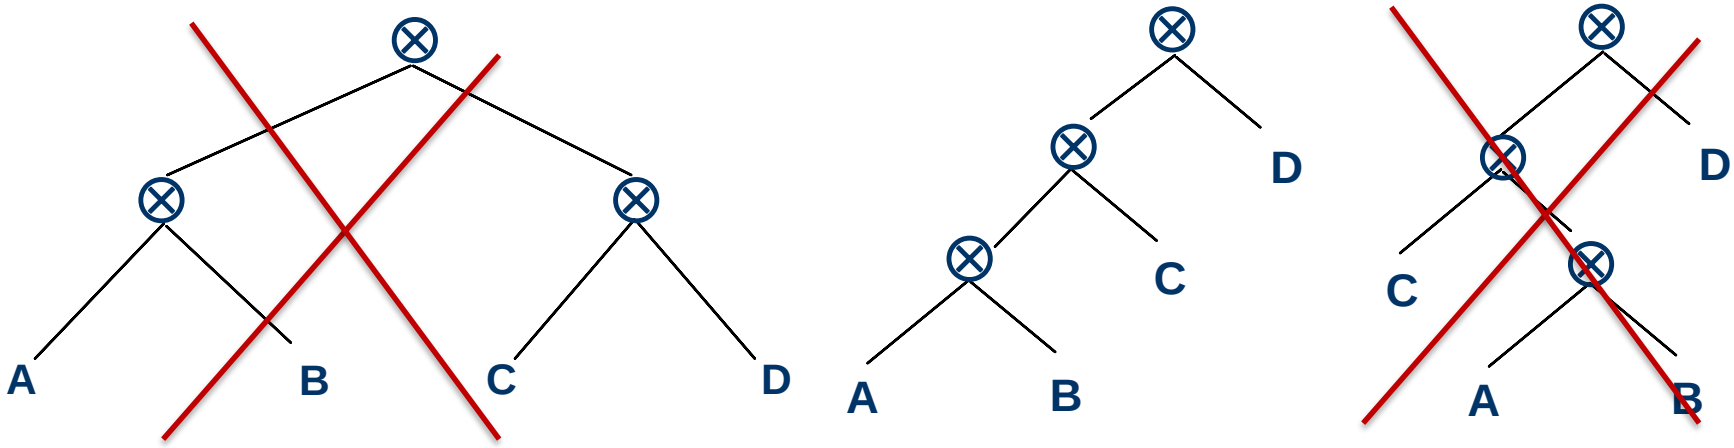

Enumerarea planurilor *left-deep*

- Planurile *left-deep* diferă prin ordinea tabelelor, metoda de acces a fiecărei tabele şi metoda utilizată pentru implementarea fiecărui *join*.
- N paşi de dezvoltare a planurilor cu N tabele:
  - Pas 1: Găsirea celui mai bun plan cu o tabelă pentru fiecare tabelă.
  - Pas 2: Găsirea celei mai bune variante de join al rezultatului unui plan cu o tabelă şi altă tabelă *(Toate planurile bazate pe 2 tabele)*
  - Pas N: Găsirea celei mai bune variante de join al rezultatului unui plan cu N-1 tabele şi altă tabelă . *(Toate planurile bazate pe N tabele)*

Enumerarea planurilor *left-deep*

- Pentru fiecare submulțime de relații, se reține:
  - Cel având costul cel mai redus, plus
  - Planul cu cel mai mic cost pentru fiecare *ordonare interesantă* a înregistrărilor.
- ORDER BY, GROUP BY, şi agregările sunt tratate la final, folosind planurile ordonate sau un operator de sortare adițional.
- Un plan bazat pe N-1 tabele nu se combină cu o altă tabelă dacă nu există o condiție de join între acestea (şi daca mai există predicate nefolosite în clauza WHERE)
  - adică se evită produsul cartezian, dacă se poate.
- În ciuda restrângerii mulțimii de planuri considerate, numărul acestora creşte exponențial cu numărul tabelelor implicate

Exemplu

Students:
Arbore B+ pt *age*
Hash pt *sid*
Evaluations:
Arbore B+ pt *cid*

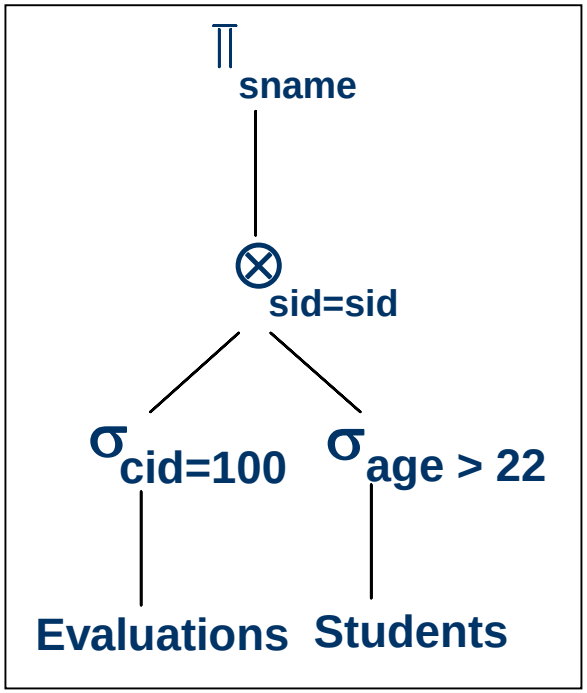

Pas 1:

- *Students*: Utilizarea arborelui B+ pentru selecția *age*>22 este cea mai puțin costisitoare. Totuşi, dacă rezultatul va avea multe înregistrări şi indexul nu este clusterizat, scana-rea tabelei poate fi mai avantajoasă.
  - Se preferă arborele B+ (deoarece rezultatul e ordonat după *age*).
- *Evaluations*: Utilizare arborelui B+ pentru selecția *cid=500* este cea mai avantajoasă.

Pas 2:

– Se consideră fiecare plan rezultat la Pas 1, şi se combină cu cea de-a doua tabelă. (ex: se foloseşte indexul Hash pe *sid* pentru selectarea înregistrărilor din *Students* ce satisfac condiția de join)

Interogări imbricate

- *Blocurile Select* imbricate sunt optimizate independent, înregistrearea curentă a bloului Select extern furnizând date pentru o condiție de selecție.
- Blocul extern e optimizat ținând cont de costul `apelului' blocului imbricat.
- Ordonarea implicită a acestor blocuri implică faptul că anumite strategii nu vor fi considerate. *Versiunile neimbricate ale unei interogări sunt (de obicei) optimizate mai bine.*

```
SELECT  S.sname
FROM  Students S
WHERE EXISTS
   (SELECT  *
    FROM  Evaluations E
    WHERE  E.cid=103
    AND  E.sid=S.sid)
```

Bloc Select de optimizat:

```
SELECT  *
FROM  Evaluations E
WHERE  E.cid=103
   AND  S.sid= valoare ext
```

Interogare simplă echivalentă :

```
SELECT  S.sname
FROM Sudents S,
Evaluations E
WHERE  S.sid=E.sid
  AND E.cid=103
```

Optimizarea interogărilor distribuite

- Abordare bazată pe cost; similară optimizării centralizate, se consideră toate planurile, alegându-se cel mai ieftin.
  - Diferență 1: Trebuie considerate costurile de transfer.
  - Diferență 2: Trebuie respectată autonomia locală a siteului.
  - Diferență 3: Se considera metode noi de join in context distribuit.

- Este creat un plan global, cu planurile local sugerate de fiecare site.
  - Dacă un site poate îmbunătății planul local sugerat, este liber să o facă.